

💡 完美列印提示：點擊右側按鈕，在列印設定中勾選「背景圖形」並取消「頁首頁尾」即可匯出完美 PDF。

🖨️ 一鍵匯出完整 A4
PDF 報告

ADVANCED LEARNING REPORT

Confidential / 技術內部研讀

MACHINE LEARNING FRAMEWORK

Top 10 機器學習演算法

深度研讀與工業落地實踐報告

📊 Top 10 Machine Learning Algorithms

第一部分：導論與基礎概念 (Introduction)

■ 監督式學習 (Supervised Learning)

訓練資料集同時包含輸入特徵 (X) 與期望的輸出標籤 (y)。演算法的目標是學習一個映射函數 f ，使得 $f(X) \approx y$ 。包含處理連續數值的回歸問題 (Regression) 與處理離散標籤的分類問題 (Classification)。

■ 非監督式學習 (Unsupervised Learning)

訓練資料集僅包含輸入特徵 (X)，沒有任何標籤 (y)。演算法的任務是在無人引導的情況下，探索資料內部的底層結構、聚集特徵或隱含模式。包含分群 (Clustering) 與特徵降維 (Dimensionality Reduction)。

© 2026 AI Knowledge Architecture Section.

Page 1

02. 圖表核心記憶線解析 (Simple Memory Line)

為了在工程實踐中快速選型，我們必須建立一套直覺的「核心記憶線 (Simple Memory Line)」，將複雜的數學公式抽象化為五大核心工程動作：

- **預測數字 (Predict Numbers)**：聚焦於定量分析。透過建立連續函數模型，追蹤變數之間的線性或非線性依賴關係。
- **分類標籤 (Classify Labels)**：聚焦於定性決策。在多維特徵空間中劃分邊界，將物件精準指派到特定的類別桶中。
- **群組資料 (Group Data)**：聚焦於物以類聚。利用距離度量，在不知道群體名稱的情況下，自動找出資料的自然聚集特徵。
- **降低特徵 (Reduce Features)**：聚焦於消除雜訊。對高度相關的特徵進行壓縮，化解「維度災難」，提升計算效率。
- **學習深度模式 (Learn Deep Patterns)**：聚焦於高階抽象。透過層層堆疊的非線性轉換，自動抽取圖像、語音、自然語言中的高維度語義特徵。

03. 初學者黃金學習路徑演進邏輯

在知識架構的建立上，圖表底部的「Recommended Learning Order for Beginners」揭示了一條從「幾何直覺」到「統計機率」，再到「集成與非線性高維抽象」的邏輯演進線：

- 1. 幾何與連續的起點 (Linear & Logistic Regression)**：這兩個算法建立在最基礎的矩陣乘法與空間幾何直線上，是所有機器學習優化演算法（如梯度下降法）的最佳實驗場。
- 2. 空間鄰近與非參數化 (KNN)**：不需做任何資料分布的假設，單純用空間距離教導初學者什麼是「資料的局部性」。
- 3. 條件分支與資訊理論 (Decision Tree → Random Forest)**：引入熵 (Entropy) 與資訊增益的概念，並透過隨機森林展示了「團體智慧 (Ensemble)」如何克服單一模型的偏見與誤差。
- 4. 統計機率與最大邊界 (Naive Bayes → SVM)**：從貝氏定理的條件機率推導，跨越到高維空間中使用拉格朗日乘子法求解最優超平面，完成了經典統計機器學習的完整訓練。
- 5. 結構重組與深度特徵 (K-Means → PCA → Neural Networks)**：從無監督的空間重組與方差壓縮，最終過渡到能夠擬合宇宙中任何複雜函數的多層神經網路。

RANK 1 線性回歸 (Linear Regression) — 連續數值預測的基石

1. 技術本質與數學原理

線性回歸假設輸入特徵 X 與輸出標籤 y 之間存在線性關係： $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n + \epsilon$ 。採用最小平方方法 (Ordinary Least Squares, OLS) 作為損失函數，優化目標為極小化均方誤差 (MSE)：

$$J(\beta) = \frac{1}{2m} \sum_{i=1}^m \left(h_{\beta}(x^{(i)}) - y^{(i)} \right)^2$$

- **優點：** 極高的可解釋性，權重物理意義明確；計算效率極高，適合大規模資料的初步基準模型。
- **缺點：** 無法捕捉非線性關係，易欠擬合；對異常值 (Outliers) 極度敏感，平方項會強烈拉偏擬合線。

真實案例： 不動產科技房價自動估價系統 (AVM)。模型方程如：房價 = 500 + 65×坪數 - 12×屋齡 - 0.2×捷運距離，為業務團隊與客戶提供極高透明度的定價邏輯。

RANK 2 邏輯回歸 (Logistic Regression) — 機率型二元分類的標準器

1. 技術本質與數學原理

邏輯回歸在線性回歸基礎上套上非線性激活函數 —— Sigmoid 函數 $\sigma(z) = \frac{1}{1 + e^{-z}}$ ，將輸出映射至 $[0, 1]$ 區間。採用交叉熵損失函數 (Cross-Entropy Loss)：

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)})) \right]$$

- **優點：** 輸出具備明確的機率意義 (如87%機率違約)，利於風控處置；計算代價小，支援串流資料線上更新。
- **缺點：** 本質上是線性分類器，只能擬合線性決策邊界。若特徵存在複雜非線性互動，極度依賴人工特徵工程。

真實案例： 信用卡交易詐欺即時偵測系統。在 50ms 內根據刷卡額升幅、地理跨度、時間段輸出盜刷機率，分級觸發直接攔截或簡訊驗證。

RANK 3 決策樹 (Decision Tree) — 具備高度可解釋性的規則樹狀圖

1. 技術本質與數學原理

決策樹透過一系列 `if-then-else` 規則對特徵空間進行矩形劃分。以 CART 樹為例，其採用吉尼不純度（Gini Impurity）作為分裂依據，遞迴切分資料以極大化吉尼增益：

$$Gini(D) = 1 - \sum_{i=1}^K p_i^2$$

● **優點：** 極致的白盒模型（White-Box），決策路徑完全可視化；無需進行特徵縮放，天生支援類別型特徵與缺失值。

● **缺點：** 極易過擬合（需嚴格限制最大深度或剪枝）；結構極不穩定，資料集微小變動即會導致整棵樹崩塌。

真實案例： 長多長照急診患者高風險住院預警。如規則：若血氧飽和度 < 90% → 立即觸發一級紅色預警，醫護人員不需懂微積分即可秒級信任決策鏈。

RANK 4 隨機森林 (Random Forest) — 集成學習與降低過擬合的經典傑作

1. 技術本質與數學原理

隨機森林是一種基於 Bagging（自助抽樣法）架構的集成演算法。具備雙重隨機性：透過有放回抽樣建立樣本隨機性，以及隨機抽取特徵子集（ $m = \sqrt{M}$ ）建立特徵隨機性。分類問題採取多數決投票：

$$\hat{y} = \arg\max_c \sum_{t=1}^T \mathbb{I}(h_t(X) = c)$$

● **優點：** 泛化能力極強，有效降低模型變異數，不易過擬合；內建特徵重要性（Feature Importance）評估功能。

● **缺點：** 失去了單一決策樹的可解釋性，模型退化為灰盒；隨著樹量增加，儲存體積與運算延遲顯著攀升。

真實案例： 跨境電商流失客戶預警系統。透過登入次數降幅、購物車未結商品數，在流失前 14 天識別出異狀並輸出核心關鍵特徵指標。

RANK 5 支持向量機 (Support Vector Machine, SVM) — 最大邊界超平面的幾何美學

1. 技術本質與數學原理

SVM 的目標是在特徵空間中尋找一個最優決策超平面 $\mathbf{w}^T \mathbf{x} + b = 0$ ，追求最大化幾何間隔 (Margin)。針對非線性分佈，引入核技巧 (Kernel Trick，如 RBF 核)，將低維線性不可分資料映射至高維度空間：

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \quad \text{subject to} \quad y^{(i)} (\mathbf{w}^T \mathbf{x}^{(i)} + b) \geq 1, \quad \forall i=1, \dots, m$$

- **優點：** 在高維空間中極其有效（即使特徵數大於樣本數）；決策僅依賴少數支持向量，記憶體高效。
- **缺點：** 不適合超大規模數據，計算複雜度呈二次方或三次方暴增；對懲罰係數 C 與 γ 核參數調參極敏感。

真實案例： 精準醫療中早期癌症基因晶片篩檢分類器。在面臨「20,000 個基因特徵、僅有百級臨床小樣本」的場景下，完美避免過擬合。

RANK 6 K-近鄰演算法 (K-Nearest Neighbors, KNN) — 基於空間距離的直覺投票法

1. 技術本質與數學原理

KNN 是一種消極學習 (Lazy Learning) 演算法。訓練期僅儲存樣本，預測期才即時計算未知樣本與數據庫中所有點的歐氏距離，選取最近的 K 個鄰居進行多數決投票：

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

- **優點：** 零訓練時間 ($\mathcal{O}(1)$)；完全非參數化，能夠完美擬合極度複雜且不規則的幾何決策邊界。
- **缺點：** 單次預測計算與記憶體成本沉重；深陷維度災難（高維空間距離失效）；對特徵縮放 (Scaling) 極度敏感。

真實案例： 晶圓廠工業物聯網 (IIoT) 高精密機台異常震動型態即時比對系統。透過 8 維頻段能量進行空間高速近鄰檢索，5ms 內抓出磨損軸承。

RANK 7 單純貝氏 (Naive Bayes) — 基於條件機率與特徵獨立假設的文字分類器

1. 技術本質與數學原理

單純貝氏基於貝氏定理 $P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$ 。它做出強烈且簡化到極致的假設：所有輸入特徵之間彼此條件獨立。因此聯合條件機率可魔術般簡化為連乘積：

$$P(\hat{y}) = \arg\max_k P(Y=k) \prod_{i=1}^n P(x_i|Y=k)$$

- 優點：

計算速度極快，本質僅是頻率統計查找表；對小規模資料與多分類任務表現極為穩健。
- 缺點：

獨立性假設在現實中基本不成立；存在零機率問題（Zero Probability，需引入拉普拉斯平滑修正）。

真實案例： SaaS 雲端服務業者客服工單自動分流引擎。利用多項式單純貝氏，以接近 0 毫秒的延遲，依內文字串頻率將工單分流至對應技術小組。

RANK 8 K-Means 分群 (K-Means Clustering) — 迭代優化質心的非監督式空間群組法

1. 技術本質與數學原理

K-Means 是一種非監督學習演算法。其核心目標是將資料劃分為 K 個指定的獨立群集，透過指派與更新兩大大步驟不斷迭代，使得每個點到其所屬群集質心 μ_k 的平方誤差和（WCSS）達到最小：

$$J = \sum_{k=1}^K \sum_{\mathbf{x}^{(i)} \in C_k} \|\mathbf{x}^{(i)} - \mu_k\|^2$$

- 優點：

運算速度極快，計算複雜度與樣本數呈線性相關 $\mathcal{O}(tKn)$ ；原理直觀，收斂速度快。
- 缺點：

K 值必須人工預先指定（需依賴肘部法判斷）；對初始質心位置極敏感，無法處理非球形幾何邊界。

真實案例： 大型零售電商會員體系「RFM 用戶精細化分眾機制」。自動切分出核心常客（低R高F高M）與流失高價值客（高R低F高M）以進行自動化精準行銷。

RANK
9

主成分分析 (Principal Component Analysis, PCA) — 保持最大方差的矩陣正交降維術

1. 技術本質與數學原理

PCA 透過座標軸旋轉，將共變異數矩陣 $\Sigma = \frac{1}{m} X^T X$ 進行特徵值分解求得特徵向量。選擇方差（特徵值）最大的前 k 個特徵向量組成轉換矩陣 W ，將高維資料正交投影過去，達成數據壓縮：

$$\Sigma \mathbf{v}_i = \lambda_i \mathbf{v}_i$$

- 優點：

徹底消除特徵間的多重共線性與冗餘；大幅壓縮資料體積，自動過濾隨機高頻噪訊。
- 缺點：

徹底喪失原始特徵的可解釋性（新特徵為舊特徵線性組合）；無法有效處理本質為非線性的高維流形。

真實案例：門禁系統高維度人臉特徵壓縮 (Eigenfaces)。將 10,000 維像素矩陣無損壓縮至 50 維，比對速度暴增 200 倍，實現毫秒級刷臉通關。

RANK
10

神經網路與深度學習 (Neural Networks / Deep Learning) — 模擬生物大腦的多層複合模式識別器

1. 技術本質與數學原理

深度學習透過前向傳播計算狀態，並利用微積分的鏈鎖律 (Chain Rule) 進行反向傳播 (Backpropagation) 更新網路數百萬個權重矩陣。單一神經元計算公式為 $a = g(\mathbf{w}^T \mathbf{x} + b)$ ，隱藏層多採 ReLU 激活函數：

$$\frac{\partial L}{\partial \mathbf{w}_l} = \frac{\partial L}{\partial \mathbf{a}_l} \cdot \frac{\partial \mathbf{a}_l}{\partial \mathbf{z}_l} \cdot \frac{\partial \mathbf{z}_l}{\partial \mathbf{w}_l}$$

- 優點：

完全自動化端到端特徵提取，省去手工特徵工程；效能隨數據與參數規模擴大呈無止境攀升。
- 缺點：

絕對的黑盒模型，內部語義無法直覺破譯；極度吞噬 GPU 算力，且高度依賴巨大的標籤資料量。

真實案例：遠距醫療平台高齡糖尿病視網膜病變 AI 自動篩檢。利用 50 層卷積神經網路 (CNN) 自動辨識微血管瘤，敏感度高達 98.2%，將預防醫學通道推延至最前線。

第三部分：工程實踐與模型評估 (Engineering Practice)

■ 混淆矩陣與工業界三大評估指標

在實際工程中，資料往往高度不平衡（例如 99.9% 正常交易與 0.1% 盜刷）。只看準確率（Accuracy）是致命陷阱。工業界標準採用以下精準度矩陣中英對照指標：

指標名稱	數學公式	核心工業物理意義
精準率 (Precision)	$\frac{TP}{TP + FP}$	預測為正樣本點中真正抓對的比例（強調降低誤報率）。適用於垃圾郵件過濾、證券推薦。
召回率 (Recall)	$\frac{TP}{TP + FN}$	全體真正正樣本中成功撈出的比例（強調降低漏報率）。適用於癌症篩檢、風控防盜刷。
F1-Score	$2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$	精準率與召回率的調和平均數，是不平衡資料集最佳的綜合單一考核分數。

■ 產線級 MLOps 生命週期五大範式

一個專業的演算法工程項目，程式碼編寫僅佔 10% 時間，其餘 90% 皆在遵循嚴格的生命週期範式迭代：

1. 資料清理 處置缺失值，利用三倍標準差法 ($\pm 3\sigma$) 自動剔除異常髒資料。	2. 特徵工程 進行 One-Hot 編碼轉換，或特徵 Z-score 標準化與歸一化。	3. 交叉驗證 標準採用 5-Fold 或 10-Fold 交叉驗證，切分集區評估真實泛化成績。	4. 網格調參 利用 Grid Search 或貝氏優化，在參數空間中榨乾模型最後潛能。	5. 概念漂移監控 封裝 API 上線，常態監控 Concept Drift，指標下滑時自動觸發管線重訓。
---	--	--	--	---